

Universidad de Santiago de Chile

Facultad de Ingeniería

Depto. de Ingeniería Informática



*Taller de minería de datos avanzada*  
*Capítulo VI*  
*“SVM Regresión y recurrencia”*

*Profesor: Dr. Max Chacón*


## Objetivos




- Introducción
- El problema de la recta de regresión
- El problema de Support Vector Regression (SVR)
- El problema de modelamiento temporal
- Recurrencias externas.

## 6.1. Support Vector Regression


Supongamos que se requiere buscar la mejor recta que ajusta a una nube de puntos  $f(\vec{x}) = \vec{w}^* \cdot \vec{x} + b$  el problema es encontrar los coeficientes  $\vec{w}$  que determinan la ecuación de la recta.



Existirá un conjunto de datos cerca de la recta que no influyen en su posición, pero los datos que se encuentran a una distancia  $> \epsilon$  controlaran mejor su ángulo.




A medida que los datos se alejan cobran más importancia para determinar la posición de la recta.



Sería bueno contar con una ponderación que aumente la importancia de los casos a medida que se alejan.

### Función $\epsilon$ -insensitiva lineal



**Elimina** todos los datos en un tubo de radio menor a  $\epsilon$  y **pondera** linealmente los casos afuera del tubo de radio  $\epsilon$

## 6.2. El problema de optimización de SVR



Se requiere determinar  $\bar{\omega}$  que genere una recta que tenga la mínima inclinación posible. Lo más parecida al modelo que se ajusta al promedio de los datos (minimizar norma de  $\bar{\omega}$ ).

Se requiere que la desviación entre  $f(\bar{x}_i)$  e  $y_i$  sea de distancia máxima  $\varepsilon$

Además es necesario ponderar los datos que quedan fuera del tubo, al igual que los vectores acotados de SVM

$$\begin{aligned} \text{Minimizar} \quad & \frac{1}{2} \|\bar{\omega}\|^2 + C \sum_{j=1}^n (\xi_j - \xi_j^*) \\ \text{s.a.} \quad & y_i - (\bar{\omega} \cdot \bar{x}_i) - b \leq \varepsilon + \xi_i \\ & (\bar{\omega} \cdot \bar{x}_i) + b - y_i \leq \varepsilon + \xi_i^* \\ & \xi_j, \xi_j^* \geq 0 \end{aligned}$$

- El Lagrangeano aumentado será:



$$\begin{aligned} L(\bar{\omega}, \xi_i, \xi_i^*, \lambda_i, \lambda_i^*, \beta_i, \beta_i^*, b) = & \frac{1}{2} \|\bar{\omega}\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) \\ & - \sum_{i=1}^n \lambda_i (\varepsilon + \xi_i - y_i + (\bar{\omega} \cdot \bar{x}_i) + b) \\ & - \sum_{i=1}^n \lambda_i^* (\varepsilon + \xi_i^* + y_i - (\bar{\omega} \cdot \bar{x}_i) - b) \\ & - \sum_{i=1}^n (\beta_i \xi_i + \beta_i^* \xi_i^*) \end{aligned} \quad (i)$$

$\bar{\omega}, \xi_i, \xi_i^*, b$  Variables del primal

$\lambda_i, \lambda_i^*, \beta_i, \beta_i^*$  Multiplicadores de Lagrange (duals)

Derivando el Lagrangeano e igualando a cero, se esta en el punto silla que permite obtener las ecuaciones en el espacio dual.



$$\frac{\partial L}{\partial \omega} = \bar{\omega} + \sum_{i=1}^n \lambda_i \bar{x}_i + \sum_{i=1}^n \lambda_i^* \bar{x}_i = 0 \quad (ii)$$

$$\frac{\partial L}{\partial b} = \sum_{i=1}^n (\lambda_i - \lambda_i^*) = 0 \quad (iii)$$

$$\frac{\partial L}{\partial \xi_i} = C - \lambda_i - \beta_i^* = 0 \quad (iv)$$

$$\frac{\partial L}{\partial \xi_i^*} = C - \lambda_i^* - \beta_i^* = 0 \quad (v)$$

Sustituyendo ii a v en i, se tiene la función objetivo en el espacio dual.

### Problema dual

$$\begin{aligned} \text{Máximizarse: } \theta(\lambda_i, \lambda_i^*) = & \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (\lambda_i - \lambda_i^*)(\lambda_j - \lambda_j^*)(\bar{x}_i \cdot \bar{x}_j) \\ & - \varepsilon \sum_{i=1}^n (\lambda_i - \lambda_i^*) + \sum_{i=1}^n y_i (\lambda_i - \lambda_i^*) \\ \text{s.a. } & \sum_{i=1}^n (\lambda_i - \lambda_i^*) = 0; \quad 0 \leq \lambda_i \leq C; \quad 0 \leq \lambda_i^* \leq C \end{aligned}$$



La solución óptima esta dada por la multiplicación de las variables duales y las restricciones del problema original (KKT).

$$\lambda_i (\varepsilon + \xi_i - y_i + (\bar{\omega} \cdot \bar{x}_i) + b) = 0 \quad (vi)$$

$$\lambda_i^* (\varepsilon + \xi_i^* + y_i - (\bar{\omega} \cdot \bar{x}_i) - b) = 0$$

$$\beta_i \xi_i = (C - \lambda_i) \xi_i = 0 \quad (vii)$$

$$\beta_i \xi_i^* = (C - \lambda_i^*) \xi_i^* = 0$$



De las ultimas dos ecuaciones (vii) se puede concluir que el  $\xi$  asociada a una muestra  $(\bar{x}_i, y_i)$  sólo puede ser distinta de cero si su  $\lambda_i$  es igual a C.

De las dos primeras ecuaciones (vi), se puede obtener los valores  $b$ , puesto que si  $0 < \lambda_i < C$ , la variable  $\xi$  será cero, entonces.

$$b = y_i - (\bar{\omega} \cdot \bar{x}_i) - \varepsilon \quad \forall \lambda_i \in ]0, C[$$

$$b = y_i - (\bar{\omega} \cdot \bar{x}_i) + \varepsilon \quad \forall \lambda_i^* \in ]0, C[$$

También se observa (de vi) que no pueden existir dos variables duales  $\lambda_i$  y  $\lambda_i^*$  que sean simultáneamente distintas de cero.

De (vi) se puede ver que para distancias de  $f(x) < \varepsilon$  el segundo factor es  $\neq 0$ , por lo tanto  $\lambda_i = 0$ .



En el caso contrario de (vi) se puede ver que para distancias de  $f(x) > \varepsilon$  el segundo factor es  $= 0$ , por lo tanto pueden ser  $\lambda_i > 0$ .

Lo anterior implica que sólo los  $\lambda_i > 0$  son los que contribuyen a la solución del problema y no se necesitan todas las  $i=1 \dots n$ , muestras para describir el problema.

Por lo tanto la ecuación de la recta original puede ser reescrita de la siguiente manera

$$f(\bar{x}) = \bar{\omega}^* \cdot \bar{x} + b = \sum_{i=1}^l (\lambda_i - \lambda_i^*) (\bar{x}_i \cdot \bar{x}) + b$$

Donde  $l$  representa los casos con  $\lambda_i > 0$ , **Vectores Soporte**

### 6.3. Tiempo y Recurrencias externas

#### Identificación de Sistemas (IS)


Metodología que consiste en construir modelos matemáticos del sistema estudiado.



#### Reglas:

- Obtención de datos de entrada y salida del sistema que se desea identificar.
- Pre-procesamiento de los datos de entrada y salida. (Examinar, limpiar y filtrar los datos).
- Elección del conjunto de modelos.
- Obtención de los parámetros del modelo y validación.
- Si modelo tiene buenos resultados (alcanzo un error aceptable), terminar sino realizar cambios en punto anterior e iterar.

#### Estructura general de la Identificación de sistemas

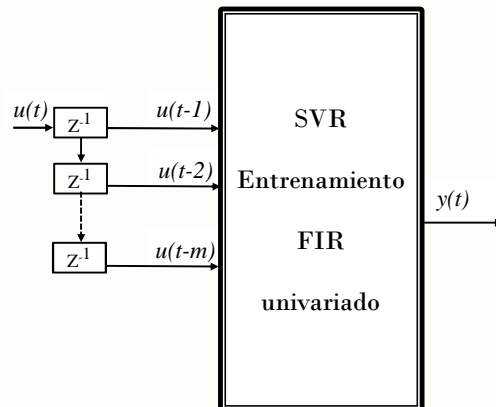


- $\hat{y}(n)$  la salida del modelo generado y  $e$  el error.
- La identificación de los parámetros de los modelos para **Sistemas en el tiempo** se basa en el error de predicción  $e(n) = y(n) - \hat{y}(n)$

## Sistemas con recurrencias externas en SVM

### ➤ Modelos FIR (o NFIR)

- Respuesta finita al impulso.
- Solo poseen memorias las entradas.
- Su estructura de aprendizaje es la siguiente



Donde el parámetro de retardos ( $m$ ) de las entradas también es un parámetro que se debe ajustar por el método de grilla.

Entonces para un modelo FIR se requiere ajustar 3 parámetros para el caso lineal y 4 para el caso no-lineal.

$C, \epsilon, m$  FIR y  $C, \epsilon, m$  y  $\gamma$  NFIR.

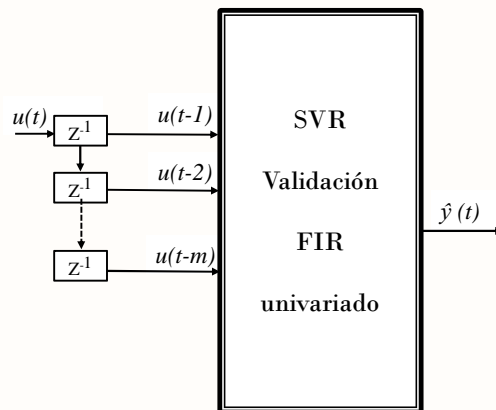
Existen algunas implementaciones, donde el ancho del tubo de la sección  $\epsilon$ -insensitiva se normaliza, para ser una proporción de los vectores de soporte.

En ese caso el parámetro se denomina  $\nu$  y varía de 0 a 1, en general se estima con pasos de 0,1.



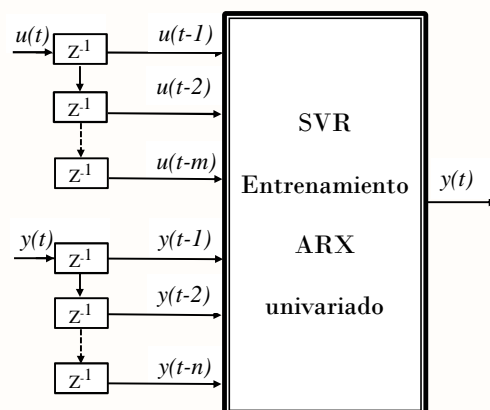


El modelo para estimar una nueva salida (producción) es el siguiente:



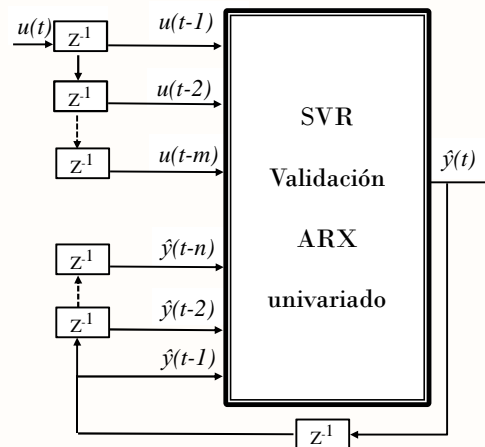
### ➤ Modelos ARX (o NARX)

Su estructura de entrenamiento es:



Esta estructura es operada One-Step-Ahead (OSA)

El modelo para estimar una nueva salida (producción) es el siguiente:



Esta estructura es operada Multiple-Prediction-Output (MPO)

Entonces para un modelo ARX se requiere ajustar 4 parámetros para el caso lineal y 5 para el caso no lineal NARX.



$C, \epsilon, m$  y  $n$  ARX y  $C, \epsilon, m, n$  y  $\gamma$  NARX.

O el caso de donde  $\epsilon$  es remplazado por  $v$